

Tugas 9: Praktikum Mandiri 9

Fatih Dzakwan Susilo - 0110224235

Teknik Informatika, STT Terpadu Nurul Fikri, Depok

E-mail: fatihdzakwansusilo@gmail.com

1. Praktikum Mandiri 9

Link Github : https://github.com/FatihDzkwn/Project_Machine_Learning.git

Link Dataset : <https://www.kaggle.com/datasets/erdemtaha/cancer-data>

1.1 Import Library

```
[128]
✓ 0 d
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, confusion_matrix, classification_report
from sklearn.preprocessing import StandardScaler
```

Gambar 1. Import Library.

Kode tersebut mempersiapkan seluruh *library* utama yang dibutuhkan untuk analisis dan pemodelan deteksi kanker, mulai dari pengolahan data dengan pandas dan numpy, visualisasi pola menggunakan matplotlib dan seaborn, pembagian data latih uji untuk membangun model, evaluasi performa melalui metrik seperti akurasi, confusion matrix, serta classification report, hingga normalisasi fitur menggunakan StandardScaler agar model dapat belajar secara optimal dari data yang telah diproses.

1.2 Menghubungkan Google Colab dengan Google Drive

```
[482]
✓ 2 d
# Mengkoneksikan Colab dengan Drive
from google.colab import drive
drive.mount('/content/drive')
```

Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).

Gambar 2. Menghubungkan Google Colab dengan Google Drive.

Tahapan ini digunakan untuk menghubungkan Colab dengan Google Drive agar dapat mengimpor dataset atau menyimpan hasil pemrosesan secara langsung.

1.3 Membaca Dataset

```
[130] ✓ 1d
cancer_data = pd.read_csv('https://drive.google.com/uc?export=download&id=1xEe_oX0hQ0UmeJ61E0neXZPC0yqMwUk')

[131] ✓ 0d
cancer_data.head()
```

	id	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	...	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst
0	842302	M	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.14710	...	17.33	184.60	2019.0	0.1622	0.6656
1	842517	M	20.57	17.77	132.90	1326.0	0.08474	0.07964	0.0869	0.07017	...	23.41	158.80	1956.0	0.1238	0.1866
2	84300903	M	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.12790	...	25.53	152.50	1709.0	0.1444	0.4245
3	84348301	M	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.10520	...	26.50	98.87	567.7	0.2098	0.8663
4	84358402	M	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.1980	0.10430	...	16.67	152.20	1575.0	0.1374	0.2050

5 rows × 33 columns

Gambar 3. Membaca Dataset.

Kode ini mengambil dataset deteksi kanker langsung dari Google Drive menggunakan `pd.read_csv`, kemudian menampilkannya dengan `head()` untuk melihat beberapa baris pertama, sehingga analis dapat memastikan struktur, kolom, dan kualitas awal data sebelum melanjutkan ke tahap eksplorasi, preprocessing, maupun pemodelan.

1.4 Data Loading & Initial Inspection

```
[132] ✓ 0d
cancer_data[9:12]
```

	id	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	...	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_worst	concave points_worst
9	84501001	M	12.46	24.04	83.97	475.9	0.11860	0.23960	0.22730	0.08543	...	40.68	97.65	711.4	0.1853	1.0580	1.1050	0.22
10	845636	M	16.02	23.24	102.70	797.8	0.08206	0.06669	0.03299	0.03323	...	33.88	123.80	1150.0	0.1181	0.1551	0.1459	0.096
11	84610002	M	15.78	17.89	103.60	781.0	0.09710	0.12920	0.09954	0.06606	...	27.28	136.50	1299.0	0.1396	0.5609	0.3965	0.18

3 rows × 33 columns

```
[133] ✓ 0d
cancer_data.tail(9)
```

	id	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	...	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_worst	concave points_worst
560	925292	B	14.05	27.15	91.38	600.4	0.09929	0.11260	0.04462	0.04304	...	33.17	100.20	706.7	0.12410	0.22640	0.1326	0.10
561	925311	B	11.20	29.37	70.67	386.0	0.07449	0.03558	0.00000	0.00000	...	38.30	75.19	439.6	0.05267	0.05494	0.0000	0.00
562	925622	M	15.22	30.62	103.40	716.9	0.10480	0.20870	0.25500	0.09429	...	42.79	128.70	915.0	0.14170	0.79170	1.1700	0.23
563	926125	M	20.92	25.09	143.00	1347.0	0.10990	0.22360	0.31740	0.14740	...	29.41	179.10	1819.0	0.14070	0.41860	0.6599	0.25
564	926424	M	21.56	22.39	142.00	1479.0	0.11100	0.11590	0.24390	0.13890	...	26.40	166.10	2027.0	0.14100	0.21130	0.4107	0.22
565	926582	M	20.13	28.25	131.20	1261.0	0.09780	0.10340	0.14400	0.09791	...	38.25	155.00	1731.0	0.11660	0.19220	0.3215	0.16
566	926954	M	16.60	28.08	108.30	858.1	0.08455	0.10230	0.09251	0.05302	...	34.12	126.70	1124.0	0.11390	0.30940	0.3403	0.14
567	927241	M	20.60	29.33	140.10	1265.0	0.11780	0.27700	0.35140	0.15200	...	39.42	184.60	1821.0	0.16500	0.86810	0.9387	0.26
568	92751	B	7.76	24.54	47.92	181.0	0.05263	0.04362	0.00000	0.00000	...	30.37	59.16	268.6	0.08996	0.06444	0.0000	0.00

9 rows × 33 columns

```
[134] ✓ 0d
cancer_data.shape
```

(569, 33)

```
[135] ✓ 0d
cancer_data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 569 entries, 0 to 568
Data columns (total 33 columns):
 #   Column              Non-Null Count  Dtype
---  ---
 0   id                  569 non-null    int64
 1   diagnosis           569 non-null    object
 2   radius_mean         569 non-null    float64
 3   texture_mean        569 non-null    float64
 4   perimeter_mean      569 non-null    float64
 5   area_mean           569 non-null    float64
 6   smoothness_mean     569 non-null    float64
 7   compactness_mean    569 non-null    float64
 8   concavity_mean       569 non-null    float64
 9   concave_points_mean 569 non-null    float64
10   symmetry_mean       569 non-null    float64
11   fractal_dimension_mean 569 non-null    float64
12   radius_se           569 non-null    float64
13   texture_se          569 non-null    float64
14   perimeter_se        569 non-null    float64
15   area_se             569 non-null    float64
16   smoothness_se       569 non-null    float64
17   compactness_se      569 non-null    float64
18   concavity_se        569 non-null    float64
19   concave_points_se   569 non-null    float64
20   symmetry_se         569 non-null    float64
21   fractal_dimension_se 569 non-null    float64
22   radius_worst        569 non-null    float64
23   texture_worst       569 non-null    float64
24   perimeter_worst     569 non-null    float64
25   area_worst          569 non-null    float64
26   smoothness_worst    569 non-null    float64
27   compactness_worst   569 non-null    float64
28   concavity_worst     569 non-null    float64
29   concave_points_worst 569 non-null    float64
30   symmetry_worst      569 non-null    float64
31   fractal_dimension_worst 569 non-null    float64
32  Unnamed: 32         0 non-null      float64
dtypes: float64(31), int64(1), object(1)
memory usage: 146.6+ KB
```

Gambar 4. Data Loading & Initial Inspection.

Dataset deteksi kanker diambil dari Google Drive dan ditampilkan sebagian untuk memahami bentuk awal datanya. Perintah `cancer_data[9:12]` dan `cancer_data.tail(9)` digunakan pada tahap Data Preview untuk melihat baris tertentu dan baris terakhir dari dataset, membantu memahami contoh data aktual. Selanjutnya, `cancer_data.shape` digunakan pada tahap Structural Overview untuk mengetahui jumlah baris dan kolom, sedangkan `cancer_data.info()` masuk dalam tahap Data Structure & Data Types Checking untuk melihat tipe data, jumlah nilai non-null, dan gambaran umum struktur dataset sebelum dilakukan pembersihan maupun analisis lebih lanjut.

1.5 Data Cleaning & Data Quality Check

```
[116] ✓ 0/0 cancer_data.isnull().sum()
```

texture_mean	0
perimeter_mean	0
area_mean	0
smoothness_mean	0
compactness_mean	0
concavity_mean	0
concave points_mean	0
symmetry_mean	0
fractal_dimension_mean	0
radius_se	0
texture_se	0
perimeter_se	0
area_se	0
smoothness_se	0
compactness_se	0
concavity_se	0
concave points_se	0
symmetry_se	0
fractal_dimension_se	0
radius_worst	0
texture_worst	0
perimeter_worst	0
area_worst	0
smoothness_worst	0
compactness_worst	0
concavity_worst	0
concave points_worst	0
symmetry_worst	0
fractal_dimension_worst	0
Unnamed: 32	569

dtype: int64

```
[117] ✓ 0/0 # Menghapus kolom  
cancer_data = cancer_data.drop(columns=['id', 'Unnamed: 32'], axis=1)
```

```
[118] ✓ 0/0 cancer_data.isnull().sum()
```

diagnosis	0
radius_mean	0
texture_mean	0
perimeter_mean	0
area_mean	0
smoothness_mean	0
compactness_mean	0
concavity_mean	0
concave points_mean	0
symmetry_mean	0
fractal_dimension_mean	0
radius_se	0
texture_se	0
perimeter_se	0
area_se	0
smoothness_se	0
compactness_se	0
concavity_se	0
concave points_se	0
symmetry_se	0
fractal_dimension_se	0
radius_worst	0
texture_worst	0
perimeter_worst	0
area_worst	0
smoothness_worst	0
compactness_worst	0
concavity_worst	0
concave points_worst	0
symmetry_worst	0
fractal dimension worst	0

```
[119] ✓ 0/0 cancer_data.describe(include='all')
```

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	symmetry_mean	...	radius_worst	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_worst	concave points_worst	symmetry_worst	fractal dimension worst
count	569	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	...	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000
unique	2	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
top	B	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
freq	357	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
mean	NaN	14.127292	19.289649	91.969033	654.889104	0.096360	0.104341	0.088799	0.048919	0.181162	...	16.269190	25.677223	107.261213	880.563128	0.132369	0.254265	0.157336	0.022832	0.157336	0.157336
std	NaN	3.524049	4.301036	24.298981	351.914129	0.014064	0.052813	0.079720	0.038803	0.027414	...	4.833242	6.146258	33.602542	569.356993	0.022832	0.157336	0.022832	0.157336	0.157336	0.157336
min	NaN	6.981000	9.710000	43.790000	143.500000	0.052630	0.019380	0.000000	0.000000	0.106000	...	7.930000	12.020000	50.410000	185.200000	0.071170	0.027290	0.071170	0.027290	0.027290	0.027290
25%	NaN	11.700000	16.170000	75.170000	420.300000	0.086370	0.064620	0.029560	0.020310	0.161900	...	13.010000	21.080000	84.110000	515.300000	0.116600	0.147200	0.147200	0.147200	0.147200	0.147200
50%	NaN	13.370000	18.840000	86.240000	551.100000	0.095870	0.092630	0.061540	0.033500	0.179200	...	14.970000	25.410000	97.660000	686.500000	0.131300	0.211900	0.211900	0.211900	0.211900	0.211900
75%	NaN	15.780000	21.800000	104.100000	782.700000	0.105300	0.130400	0.130700	0.074000	0.195700	...	18.790000	29.720000	125.400000	1084.000000	0.146000	0.339100	0.339100	0.339100	0.339100	0.339100
max	NaN	26.110000	39.280000	188.500000	2501.000000	0.163400	0.345400	0.426800	0.201200	0.304000	...	36.040000	49.540000	251.200000	4254.000000	0.222600	1.050000	1.050000	1.050000	1.050000	1.050000

11 rows × 31 columns

Gambar 5. Data Cleaning & Data Quality Check.

Dimulai dengan `cancer_data.isnull().sum()` untuk mengecek keberadaan nilai kosong pada setiap kolom. Setelah diketahui ada kolom yang tidak relevan, langkah Feature Removal dilakukan dengan menghapus kolom `id` dan `Unnamed: 32` agar analisis lebih bersih dan fokus pada fitur penting. Terakhir, `cancer_data.describe(include='all')` digunakan pada tahap Descriptive Statistics untuk memberikan ringkasan statistik seluruh kolom, baik numerik maupun kategorikal, sehingga memberikan gambaran umum distribusi data sebelum masuk ke tahap analisis lanjutan.

1.6 Data Segmentation

```

M = cancer_data[cancer_data.diagnosis == "M"]
M.head(5)

```

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	symmetry_mean	...	radius_worst	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_worst
0	M	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.14710	0.2419	...	25.38	17.33	184.60	2019.0	0.1622	0.6656	
1	M	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.07017	0.1812	...	24.99	23.41	158.80	1956.0	0.1238	0.1866	
2	M	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.12790	0.2069	...	23.57	25.53	152.50	1709.0	0.1444	0.4245	
3	M	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.10520	0.2597	...	14.91	26.50	98.87	567.7	0.2098	0.8663	
4	M	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.1980	0.10430	0.1809	...	22.54	16.67	152.20	1575.0	0.1374	0.2050	

```

B = cancer_data[cancer_data.diagnosis == "B"]
B.head(5)


```

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	symmetry_mean	...	radius_worst	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_worst
19	B	13.540	14.36	87.46	566.3	0.09779	0.08129	0.06664	0.047810	0.1885	...	15.110	19.26	99.70	711.2	0.14400	0.17730	
20	B	13.080	15.71	85.63	520.0	0.10750	0.12700	0.04568	0.031100	0.1967	...	14.500	20.49	96.09	630.5	0.13120	0.27760	
21	B	9.504	12.44	60.34	273.9	0.10240	0.06492	0.02956	0.020760	0.1815	...	10.230	15.66	65.13	314.9	0.13240	0.11480	
37	B	13.030	18.42	82.61	523.8	0.08963	0.03766	0.02562	0.029230	0.1467	...	13.300	22.81	84.46	545.9	0.09701	0.04619	
46	B	8.196	16.84	51.71	201.9	0.08600	0.05943	0.01588	0.005917	0.1769	...	8.964	21.96	57.26	242.2	0.12970	0.13570	

Gambar 6. Data Segmentation.

Dataset deteksi kanker dipisahkan berdasarkan kategori diagnosis untuk memudahkan analisis per kelas. Baris `M = cancer_data[cancer_data.diagnosis == "M"]` dan `B = cancer_data[cancer_data.diagnosis == "B"]` memisahkan data tumor berjenis Malignant (M) dan Benign (B). Kemudian `M.head(5)` dan `B.head(5)` digunakan pada tahap Sample Inspection, yaitu menampilkan contoh lima baris pertama dari masing-masing subset agar analisis dapat membandingkan pola atau karakteristik awal antara kedua kategori sebelum masuk ke tahap eksplorasi lebih dalam.

1.7 Data Visualization



Gambar 7. Data Visualization.

Memahami perbedaan pola antara tumor Malignant dan Benign. Scatter plot dibuat dengan sumbu *Radius Mean* dan *Texture Mean* untuk melihat distribusi kedua kelas, di mana data Malignant divisualisasikan dengan warna merah dan Benign dengan warna hijau (lime) menggunakan transparansi (*alpha*) agar pola sebaran lebih jelas. Pemberian judul, label sumbu, dan legenda termasuk dalam tahap Chart Labelling & Interpretation Support, membantu analisis mengidentifikasi apakah kedua kelas memiliki pemisahan visual yang kuat sebelum melanjutkan ke pemodelan machine learning.

1.8 Data Preprocessing

```

[145] cancer_data.diagnosis = [1 if i == "M" else 0 for i in cancer_data.diagnosis]
✓ 0 d

[146] x = cancer_data.drop(["diagnosis"], axis = 1)
✓ 0 d y = cancer_data.diagnosis.values

[147] # Normalization:
✓ 0 d x = (x - np.min(x)) / (np.max(x) - np.min(x))

[148] x_train, x_test, y_train, y_test = train_test_split(x, y, test_size = 0.3, random_state = 42)
✓ 0 d

[149] print(x.shape, x_train.shape, x_test.shape)
✓ 0 d
(569, 30) (398, 30) (171, 30)

[150] scaler = StandardScaler()
✓ 0 d X_train_scaled = scaler.fit_transform(x_train)
X_test_scaled = scaler.transform(x_test)

```

Gambar 8. Data Preprocessing.

Dimulai dari mengubah label diagnosis menjadi format numerik biner (Malignant = 1, Benign = 0) agar kompatibel dengan algoritma machine learning. Selanjutnya, fitur dipisahkan menjadi variabel input (x) dan output (y). Pada tahap Normalization, setiap fitur dinormalisasi menggunakan metode *min-max scaling* untuk menyeragamkan skala data. Kemudian dilakukan Train-Test Split dengan membagi data menjadi 70% pelatihan dan 30% pengujian. Setelah itu, tahap Feature Scaling dilakukan menggunakan StandardScaler untuk menstandarisasi data (mean = 0, standar deviasi = 1), memastikan semua fitur memiliki skala yang seimbang sehingga model dapat belajar lebih efektif dan stabil pada proses pelatihan.

1.9 Model Training & Evaluation

```

[151] nb = GaussianNB()
✓ 0 d nb.fit(x_train, y_train)

GaussianNB
GaussianNB()

[152] # Accuracy
✓ 0 d train_pred_nb = nb.predict(x_train)
test_pred_nb = nb.predict(x_test)

[153] print("Training Accuracy (NB): ", accuracy_score(y_train, train_pred_nb))
✓ 0 d print("Testing Accuracy (NB): ", accuracy_score(y_test, test_pred_nb))


Training Accuracy (NB): 0.9396984924623115
Testing Accuracy (NB): 0.9415204678362573

```

Gambar 9. Model Training & Evaluation.

Dimulai dengan membuat model *Gaussian Naive Bayes* (`GaussianNB()`) dan melatihnya menggunakan data *training* untuk mempelajari pola klasifikasi antara tumor malignant dan benign. Setelah model dilatih, dilakukan prediksi pada data *train* dan *test* untuk mengevaluasi performa model. Nilai akurasi kemudian dihitung menggunakan `accuracy_score` pada tahap Model Performance Assessment, yang menunjukkan seberapa baik model mengenali kelas tumor pada data yang sudah dikenal (training) maupun data baru (testing), sebagai indikator awal efektivitas model klasifikasi Naive Bayes dalam mendeteksi kanker.

1.10 Model Evaluation & Error Analysis



Gambar 10. Model Evaluation & Error Analysis.

Confusion matrix dibuat untuk mengevaluasi lebih detail performa model Naive Bayes dalam membedakan tumor benign dan malignant. Confusion matrix dihitung menggunakan `confusion_matrix` lalu divisualisasikan dalam bentuk heatmap menggunakan `seaborn` pada tahap Model Result Visualization. Label pada sumbu X dan Y menunjukkan prediksi dan kondisi aktual, sementara anotasi angka pada kotak membantu melihat jumlah prediksi benar dan salah untuk

masing-masing kelas. Plot diberi judul dan label sumbu untuk memperjelas interpretasi, sehingga analis dapat memahami pola kesalahan model dan seberapa baik model bekerja dalam mendeteksi kanker secara akurat.

1.11 Model Performance Reporting

```
[185]
✓ 0d
print("\nClassification Report (NB):")
print(classification_report(y_test, test_pred_nb))
```

...

	precision	recall	f1-score	support
0	0.95	0.96	0.95	108
1	0.93	0.90	0.92	63
accuracy			0.94	171
macro avg	0.94	0.93	0.94	171
weighted avg	0.94	0.94	0.94	171

Gambar 11. Model Performance Reporting.

Classification_report digunakan untuk menampilkan metrik evaluasi lengkap model Naive Bayes meliputi precision, recall, f1-score, dan support untuk masing-masing kelas (benign dan malignant). Laporan ini membantu pada tahap Detailed Metrics Interpretation karena memberikan gambaran seberapa baik model dalam mengenali setiap kelas, terutama apakah model mampu mendeteksi tumor malignant dengan sensitivitas tinggi. Output ini melengkapi analisis sebelumnya seperti akurasi dan confusion matrix, sehingga evaluasi performa model menjadi lebih komprehensif dan informatif.

1.12 Model Validation & Generalization Testing

```
[186]
✓ 0d
from sklearn.model_selection import cross_val_score
cv_nb = cross_val_score(nb, x, y, cv=5, scoring='accuracy')
print("\nNaive Bayes Cross Validation Accuracy (5-Fold):")
print("Scores:", cv_nb)
print("Mean Accuracy:", cv_nb.mean())
print("Std Deviation:", cv_nb.std())
```

...

```
Naive Bayes Cross Validation Accuracy (5-Fold):
Scores: [0.92105263 0.92105263 0.94736842 0.94736842 0.95575221]
Mean Accuracy: 0.9385188635305075
Std Deviation: 0.014585994424363306
```

Gambar 12. Model Validation & Generalization Testing.

cross_val_score digunakan untuk melakukan 5-Fold Cross Validation pada model Naive Bayes untuk menilai konsistensi performa model di berbagai pembagian data. Dengan menggunakan metrik akurasi pada setiap fold, proses ini membantu mengevaluasi apakah model benar-benar mampu melakukan generalisasi dengan baik, bukan hanya kebetulan bekerja bagus pada satu pembagian data tertentu. Hasil berupa deretan skor akurasi, rata-rata akurasi, serta standar

deviasi ditampilkan pada tahap Stability & Robustness Assessment, yang menunjukkan seberapa stabil dan reliabel performa model ketika diuji pada banyak subset data secara berbeda.